Pérdida económica por maquinaria vial bajo custodia

Regresión + alerta crítica: informe final del TP Integrador de Aprendizaje Automático

Dato	Detalle
Grupo	Grupo 5
Integrantes	Maciel Fátima · Díaz José · Carrera Carla · Sarmiento Rodrigo
Curso / fechas	*(completar: curso, fecha de inicio y fecha de entrega final)*
Repositorio	*(completar: URL del repositorio)* · etiqueta **entrega-5-final**
Aplicación publicada	*(completar: URL https://<proyecto>.vercel.app)*
Reproducibilidad	Semilla 42 · Python 3.12.3 · scikit-learn 1.8.0

Aviso. Los datos de este trabajo son **simulados**. Las métricas describen el desempeño dentro de la simulación y no prueban capacidad predictiva sobre pérdidas reales. El umbral (USD 100.000) y los costos (falso negativo = 5, falso positivo = 1) son supuestos didácticos explicados en las secciones 3 y 11.

1. Problema, usuario y decisión

Un organismo que custodia maquinaria vial inmovilizada (motoniveladoras, excavadoras, topadoras, etc.) debe decidir qué equipos atender primero —reparar, reasignar o rematar— porque cada mes de inactividad acumula una pérdida económica. Con recursos limitados necesita anticipar **cuánto** se espera perder con cada equipo y **si esa pérdida será crítica**.

Elemento	Definición
Usuario de la predicción	Área administrativa que gestiona la custodia de los bienes.
Decisión	Priorizar la revisión/intervención de los equipos con pérdida esperada crítica.
Momento de la predicción	Inspección inicial del equipo, con los meses de inactividad acumulados a la fecha de la consulta. Solo se usan datos conocidos en ese momento.
Regresión	**perdida_economica_usd**: pérdida económica estimada (USD).
Clasificación	**perdida_critica** = 1 si perdida_economica_usd ≥ 100.000 USD; 0 en caso contrario.

2. Datos: origen, diccionario y controles de calidad

Fuente. No existe una fuente externa: el dataset lo genera el grupo en la sección 2 del notebook con semilla 42, a partir de una fórmula documentada en *datos/README.md*. Se optó por simular porque no se dispuso de un repositorio público con datos normalizados de maquinaria bajo custodia. Cada fila representa **un equipo inspeccionado al ingresar a custodia**. No hay datos personales.

La pérdida se simula como *valor_actual* × *0,012* × *meses* × *factor_estado* × *factor_provincia* × *ruido*, con depreciación del 4 % anual. Los cinco predictores influyen en el resultado; por eso **las relaciones aprendidas son las de la fórmula, no relaciones reales**.

Variable	Tipo	Rol	Descripción / rango
tipo_equipo	categórica	Predictor	6 tipos (Motoniveladora, Excavadora, Retroexcavadora, Cargadora frontal, Rodillo compactador, Topadora)
provincia	categórica	Predictor	Buenos Aires, Córdoba, Santa Fe, Mendoza, Salta
meses_inactividad	numérica	Predictor	Meses de inactividad a la fecha de la consulta (1 a 120)
anio_fabricacion	entera	Predictor	2000 a 2026
estado_motor	categórica	Predictor	Funcional, Requiere_Reparacion, Averia_Grave (inspección inicial)
perdida_economica_usd	numérica	Objetivo regresión	Pérdida en USD (≥ 0)
perdida_critica	binaria	Objetivo clasificación	1 si pérdida ≥ 100.000
id_registro	texto	Descartada	Identificador sin valor predictivo

Controles de calidad. El dataset crudo (2.520 filas) se generó con problemas intencionales para practicar la limpieza:

Control	Hallazgo	Acción
Duplicados completos	20	Eliminados (un equipo no debe contarse dos veces)
meses_inactividad imposible (−3 y 999)	10	Fila eliminada (no se conoce el valor real)
meses_inactividad faltante	51 (50 tras quitar duplicados)	Fila eliminada; no se imputa para no inventar la variable principal ni filtrar información de test
Categorías desconocidas / años fuera de rango	0	—

Control	Hallazgo	Acción
Resultado	2.440 filas, sin nulos	Dataset preparado (≥ 2.000 registros)

Fuga de información. Ningún predictor contiene el resultado: las variables objetivo y el identificador quedan fuera de las entradas, y los cinco predictores se conocen al momento de la inspección. La transformación (escalado y codificación) se ajusta solo con entrenamiento, dentro del Pipeline.

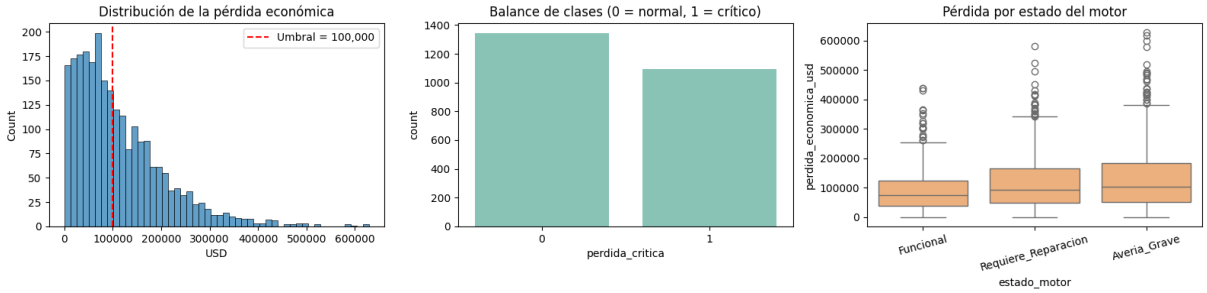


Figura 1. Distribución de la pérdida (cola larga a la derecha, con el umbral en rojo), balance de clases (≈ 45 % críticos) y pérdida por estado del motor.

3. Umbral y esquema de costos

Umbral = USD 100.000. Es el nivel de pérdida a partir del cual el equipo pasa a revisión prioritaria; se aplica con ≥ en datos, notebook, aplicación e informe. Es un supuesto didáctico (ver sección 11); deja ≈ 45 % de casos críticos, de modo que las clases están razonablemente balanceadas y el accuracy del baseline (≈ 55 %) no es engañoso.

Error	Significado en este problema	Costo relativo
Falso negativo (FN)	El sistema dice «normal» pero la pérdida era crítica: un equipo urgente queda sin atender y sigue acumulando pérdida mes a mes.	5
Falso positivo (FP)	El sistema dice «crítico» pero no lo era: se hace una revisión innecesaria (tiempo de inspección).	1

Criterio. Un FN cuesta más porque la pérdida se acumula mensualmente hasta que alguien actúa, mientras que un FP solo consume una inspección. La proporción 5:1 es un supuesto; por eso se informa una tabla de sensibilidad (1:1, 3:1, 5:1 y 10:1) en la sección 8.

4. Protocolo de evaluación

- Partición **60 / 20 / 20** (entrenamiento 1.464, validación 488, test 488), estratificada por la clase y con semilla 42; **los mismos casos** se usan para regresión y clasificación.
- El test se separa antes de comparar modelos y solo se usa una vez, al final. Los modelos y los hiperparámetros se eligen con **validación**.
- Escalado y codificación (StandardScaler y OneHotEncoder) dentro de un **Pipeline** ajustado solo con entrenamiento.
- Regresión: MAE, RMSE y R^2. Clasificación: accuracy, precision, recall, F1, matriz de confusión y costo total (5·FN + FP).
- Todos los modelos se comparan contra su baseline (DummyRegressor con la media; DummyClassifier con la clase más frecuente).

5. Baselines

En test, el **DummyRegressor** obtiene MAE USD 71.057, RMSE USD 92.758 y $R^2 \approx 0$: siempre predice la media. El **DummyClassifier** (siempre «no crítico») logra accuracy 0,551 pero recall 0 y costo 1.095: no detecta ningún equipo crítico. Estos valores son el piso que cualquier modelo útil debe superar.

6. Regresión

Se compararon DummyRegressor, DecisionTreeRegressor (profundidades 3, 5 y 10) y KNeighborsRegressor (k = 5 y 15) con StandardScaler dentro del Pipeline. Resultados en **validación**:

Modelo	MAE (USD)	RMSE (USD)	R^2
Dummy (media)	68.849	86.833	−0,005
Árbol prof=3	36.431	52.206	0,637
Árbol prof=5	29.832	42.576	0,758
Árbol prof=10	19.954	29.098	0,887
KNN k=5	22.493	31.929	0,864
KNN k=15 (seleccionado)	**18.858**	**26.590**	**0,906**

Un árbol muy poco profundo no captura las interacciones entre tipo, meses y estado; el error baja al aumentar la profundidad y, entre los KNN, k = 15 promedia más vecinos y reduce la varianza. Se eligió **KNN k=15** por menor MAE en validación.

Test (una sola vez): MAE USD 20.619, RMSE USD 31.841, R^2 0,882, frente a MAE USD 71.057 del baseline (reducción del 71.0 %). **Interpretación del MAE:** la estimación de la pérdida se desvía, en promedio, USD 20.619 por equipo, es decir, un 21 % del umbral y un 18 % de la pérdida media del test (USD 111.811). El R^2 alto es consecuencia de que los datos salen de una fórmula; no implica capacidad real.

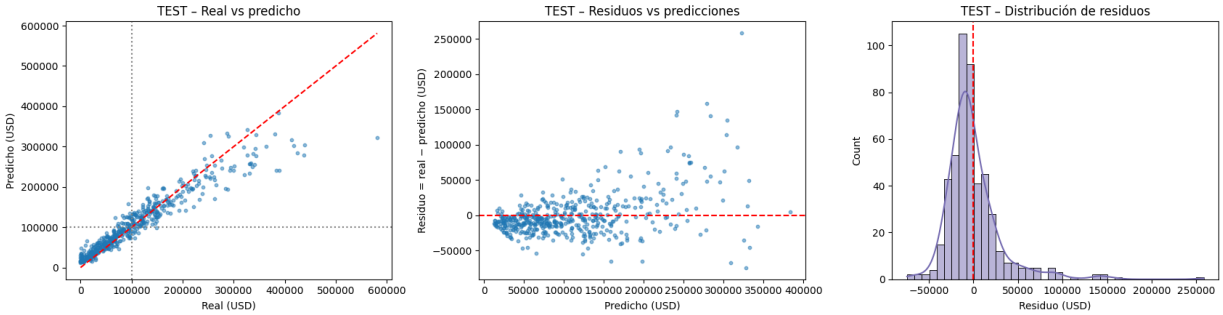


Figura 2. Test: real vs predicho, residuos vs predicción y distribución de residuos (residuo = real − predicho).

Residuos. El residuo medio es casi cero (USD −132) y la mediana es −6.290: el modelo sobreestima en el 64 % de los casos y subestima en el 36 %. La dispersión crece con la pérdida predicha (heterocedasticidad) porque el ruido de la simulación es multiplicativo. **Errores importantes:** los 10 mayores errores absolutos (USD 93.000 a 258.000) son **subestimaciones** de equipos de alto valor (Topadora y Motoniveladora) con muchos meses de inactividad (p. ej., Topadora en Salta, 112 meses: real 581.198 vs predicho 322.953). KNN promedia vecinos y «aplana» los extremos. Como en todos esos casos la estimación sigue estando por encima del umbral, el error numérico grande **no cambia la alerta**.

7. Clasificación

Se compararon DummyClassifier, DecisionTreeClassifier (profundidades 3, 5, 10), KNeighborsClassifier (k = 5 y 15, con StandardScaler en el Pipeline) y GaussianNB. Resultados en **validación** (costo = 5·FN + FP):

Modelo	Accuracy	Precision	Recall	F1	FP	FN	Costo
Dummy (más frecuente)	0,551	0,000	0,000	0,000	0	219	1.095
Árbol prof=3	0,828	0,763	0,895	0,824	61	23	176
Árbol prof=5	0,891	0,915	0,836	0,874	17	36	197
Árbol prof=10 (seleccionado)	**0,930**	**0,947**	**0,895**	**0,920**	**11**	**23**	**126**
KNN k=5	0,904	0,930	0,849	0,888	14	33	179

Modelo	Accuracy	Precision	Recall	F1	FP	FN	Costo
KNN k=15	0,922	0,925	0,900	0,912	16	22	126
GaussianNB	0,853	0,848	0,817	0,833	32	40	232

Selección. Árbol prof=10 y KNN k=15 empataron en costo (126). El criterio de desempate (mayor F1 en validación) se fijó de antemano en el notebook y favorece al árbol (0,920 vs 0,912). GaussianNB queda último porque supone independencia entre variables, algo que la fórmula multiplicativa no cumple.

Test (una sola vez), Árbol prof=10: accuracy 0,904, precision 0,891, recall 0,895, F1 0,893; matriz: TN 245, FP 24, FN 23, TP 196; costo 139. El baseline obtiene recall 0 y costo 1.095.

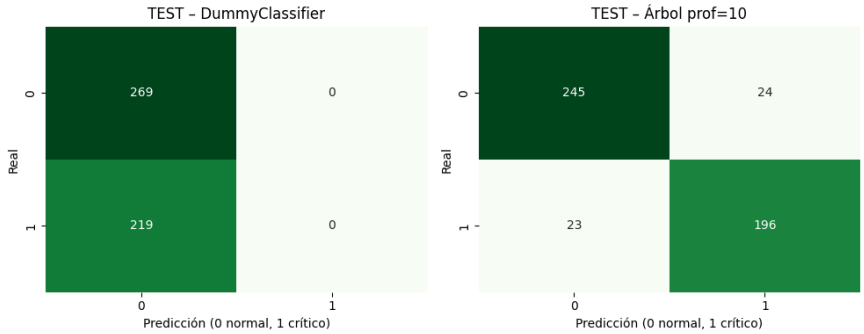


Figura 3. Test: matrices de confusión del DummyClassifier y del clasificador seleccionado.

8. Comparación integrada: clasificador directo vs regresión + umbral

Ambos sistemas se evalúan sobre **los mismos 488 casos de test**. El clasificador directo predice la clase; la regresión + umbral predice USD y aplica «estimación ≥ 100.000».

Sistema	Accuracy	Precision	Recall	F1	FP	FN	Costo (5·FN+FP)
Clasificador directo (Árbol prof=10)	0,904	0,891	0,895	0,893	24	23	139
Regresión + umbral (KNN k=15)	**0,934**	0,898	**0,963**	**0,930**	24	**8**	**64**

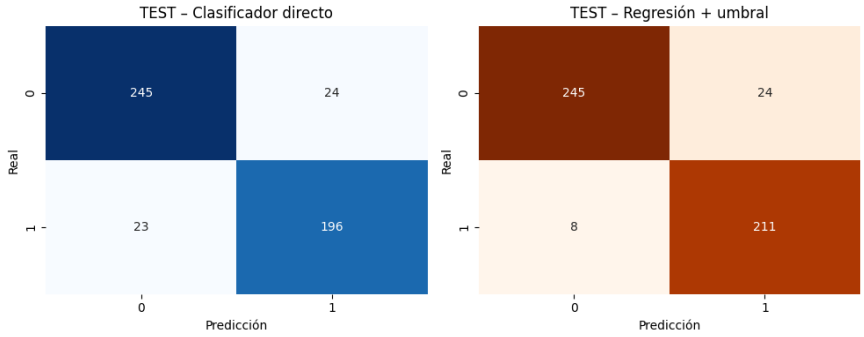


Figura 4. Test: matrices de confusión de los dos sistemas.

Ambos producen los mismos 24 falsos positivos, pero la regresión + umbral reduce los falsos negativos de 23 a 8. **Sensibilidad a los costos** (costo total en test = r·FN + FP):

Costo FN : FP	Clasificador directo	Regresión + umbral
1 : 1	47	32
3 : 1	93	48
5 : 1	139	64
10 : 1	254	104

La regresión + umbral resulta mejor con cualquiera de las proporciones probadas, así que la conclusión no depende de haber elegido 5:1.

Casos cercanos al umbral. Hay 48 casos de test con estimación a ≤ USD 10.000 del umbral: concentran 16 de los 32 errores de regresión + umbral (33 % de error dentro de esa franja frente a 4 % fuera de ella). Los dos sistemas discrepan en 53 de los 488 casos.

Casos concretos con buen error numérico y alerta incorrecta (regresión + umbral; el error absoluto es menor o igual al MAE de USD 20.619):

Real (USD)	Predicho (USD)	Error abs. (USD)	Real crítico	Alerta regresión+umbral	Alerta directa	Consecuencia
89.877	101.290	11.413	0	1	1	FP: revisión innecesaria
96.853	102.561	5.708	0	1	1	FP: revisión innecesaria
110.586	96.319	14.268	1	0	1	FN: equipo crítico sin atender (el directo acierta)
95.309	105.403	10.094	0	1	0	FP (el directo acierta)
99.084	106.594	7.510	0	1	1	FP: revisión innecesaria
106.863	90.840	16.023	1	0	1	FN: equipo crítico sin atender (el directo acierta)

Doce de los 32 errores de alerta de la regresión + umbral tuvieron un error numérico menor o igual al MAE: el modelo estuvo «cerca», pero cruzó el umbral.

9. Respuestas a las preguntas del informe

1. ¿El modelo de regresión supera al baseline?

Sí. MAE USD 20.619 contra USD 71.057 del DummyRegressor (−71 %) y R^2 0,882 contra ≈ 0.

2. ¿Qué significa el MAE en el contexto elegido?

La pérdida estimada de un equipo se aleja del valor real, en promedio, USD 20.619; equivale a un 21 % del umbral. Es un error comparable a la distancia que separa un caso normal de uno crítico cuando está cerca del límite.

3. ¿Qué modelo detecta mejor los casos críticos?

La regresión + umbral: recall 0,963 (8 FN) frente a 0,895 (23 FN) del clasificador directo.

4. ¿Qué errores son más costosos?

Los falsos negativos (supuesto 5:1): un equipo crítico queda sin atender y acumula pérdida mensual. Con ese esquema el costo total es 139 para el directo y 64 para la regresión + umbral.

5. ¿Qué sucede con los casos cercanos al umbral?

Allí se concentran los errores: 33 % de error a ≤ USD 10.000 del umbral contra 4 % fuera de la franja. Un desvío pequeño del modelo alcanza para cruzar el límite.

6. ¿Es posible obtener un buen MAE y una mala clasificación?

Sí. 12 de los 32 errores de alerta de la regresión + umbral tuvieron un error numérico menor o igual al MAE (tabla de la sección 8).

7. ¿Qué sistema recomendarían y por qué?

La regresión + umbral: menor costo en todas las proporciones probadas, menos falsos negativos y además entrega el monto estimado. Se recomienda mostrar ambas alertas y derivar a revisión manual los casos en que discrepan y los cercanos al umbral.

8. ¿En qué situaciones no debería utilizarse la solución?

Con equipos reales (los modelos se entrenaron con datos simulados), sin validar umbral y costos con datos observados, como dictamen pericial, y con valores fuera de los rangos de entrenamiento (meses 1–120, años 2000–2026), donde KNN y el árbol no extrapolan.

10. Aplicación web y despliegue

La aplicación Flask (*app.py*) **solo carga** los dos Pipelines guardados con joblib y ejecuta *predict*; no entrena, no acepta archivos joblib/pickle externos y no usa base de datos. Las categorías, rangos y el umbral se leen de *modelos/metadata.json*, escrito por el notebook.

- **Formulario** con las cinco variables y **validación en el servidor** (categorías permitidas, rangos, valores no numéricos, NaN, infinitos, campos ausentes, tamaño de solicitud).
- Muestra la **pérdida estimada**, la **alerta por regresión + umbral**, la **alerta del clasificador directo**, si **coinciden o discrepan**, la distancia al umbral y una interpretación en lenguaje comprensible (con aviso si el caso está a menos de un MAE del umbral).
- **Tablero de flota**: tabla de hasta 100 equipos del dataset preparado con filtros por tipo y provincia, proyección de meses de inactividad a futuro y dictamen visual (operativa / atención / urgente / inviable). Solo el «Lucro Cesante Estimado» proviene del modelo de regresión; el valor de mercado, el costo de puesta en marcha y el dictamen son una simulación visual con valores de referencia supuestos, y el dictamen «urgente» usa la misma regla ≥ umbral.
- **Advertencias** sobre datos simulados, supuestos y cuándo no usar la herramienta.
- Verifica que la versión de scikit-learn coincida con la usada al entrenar; si falta un modelo o no coincide, informa el error y **no entrena**. Ruta */salud* para verificar el estado.
- **24 pruebas funcionales** (*python -m unittest discover -s pruebas -v*), todas aprobadas; incluyen la regla ≥ en el umbral exacto, la coincidencia con los artefactos del notebook y el comportamiento del tablero (filtros, proyección, parámetros inválidos, ausencia del CSV).

Despliegue en Vercel. Se sube el repositorio a GitHub, se importa en Vercel (detecta Flask a partir de *app.py*, *requirements.txt* y *.python-version*) y se prueba la URL desde otro dispositivo. El *requirements.txt* contiene solo las dependencias de la aplicación; matplotlib y seaborn (solo para el notebook) están en *requirements-notebook.txt* para aligerar el despliegue.

URL pública: *(completar tras el despliegue)* · **Probada desde otro dispositivo:** *(completar: fecha y dispositivo)*

11. Limitaciones

- **Datos simulados.** Los modelos aprenden la fórmula de simulación; el R^2 (0,88) y el accuracy no son evidencia de capacidad predictiva real. Con datos reales se esperan métricas menores y distintas relaciones.
- **Umbral y costos supuestos.** USD 100.000 y la razón 5:1 no provienen de datos observados; deben validarse con el organismo antes de un uso operativo.
- **Una única partición.** Las diferencias entre sistemas (p. ej., 8 vs 23 falsos negativos) provienen de un solo test de 488 casos; no se midió su variabilidad.
- **Extremos.** KNN y los árboles subestiman las pérdidas más altas y no extrapolan fuera de los rangos de entrenamiento.
- **Alcance.** La herramienta apoya la priorización; no sustituye una evaluación pericial.

12. Reproducibilidad

Elemento	Detalle
Versiones	Python 3.12.3 · numpy 2.4.4 · pandas 3.0.2 · scikit-learn 1.8.0 · joblib 1.5.3
Semilla	42 (datos, particiones y modelos)
Instalación	pip install -r requirements-notebook.txt y pip install notebook

Elemento	Detalle
Notebook	notebooks/entrenamiento.ipynb → Kernel > Restart & Run All (genera datos/ y modelos/)
Aplicación	python app.py → http://127.0.0.1:5001/
Pruebas	python -m unittest discover -s pruebas -v

13. Anexo: relación con la propuesta de la Entrega 1

La Entrega 1 presentó tres alternativas; la Alternativa 1 (tasación de maquinaria pesada con datos de Mercado Libre/Kaggle y umbral de ARS 15.000.000) fue el punto de partida. El proyecto final mantiene el sector (maquinaria pesada bajo custodia del Estado) y la lógica regresión + umbral, pero cambia la variable numérica a la **pérdida económica** y usa datos simulados por no contar con un repositorio público adecuado. El cambio y su motivo están registrados en la bitácora de decisiones.